Онтология и база знаний по исполнителям из списка «100 величайших исполнителей всех времён» журнала Rolling Stone

Введение и сводка результатов

Цель работы. Спроектировать и построить базу знаний для выбранной предметной области: определить вопросы, на которые она должна отвечать, разработать под них онтологию, наполнить её данными из Wikidata, проверить данные и получить ответы запросами к графу

Предметная область. Люди из списка «100 величайших исполнителей всех времён по версии журнала Rolling Stone» (русская Википедия). Позиции списка, не являющиеся людьми (группы), в домен не входят; в data/domain.csv остались 53 человека (ранги от 2 до 99). Источники данных — Wikidata Query Service и API Wikidata/Википедии.
Ниже — сводка по заданиям.

Задание	Результат
1. Домен	53 сущности класса Q5; у 53 из 53 заполнено ≥ 5 свойств (min 10, медиана 14, max 17); дата и число + ≥ 5 свойств — у 41 из 53 (77%); найдено 9 свойств с квалификатором времени; текстовый источник есть у 53 из 53
2. Вопросы	12 вопросов: 6 по графу, 4 по тексту, 2 комбинированных; эталоны всех 12 совпали с результатами запуска
3. Онтология	15 классов (6 отношений подкласса), 12 object- и 15 datatype-свойств, 15 функциональных; 9 классов и 15 свойств связаны с Wikidata; все требования проверены скриптом
4. Граф	7 738 троек; 1 538 узлов с типом (798 с owl:sameAs на Wikidata, 53 из них — музыканты); 13 классов; 30 предикатов
5. Корпус	106 документов (ru + en Википедия) для 53 сущностей; 4 363 148 символов
6. Проверка и вывод	pyshacl: Conforms = True, 79 предупреждений одного вида (awardYear); owlrl: добавлено 26 518 троек, из них значимых 18 164

Организация работы. Работа выполнена индивидуально

1. Выбор и проверка домена

Домен — люди (Q5) из списка Rolling Stone 100. Скрипт task1_collect_domain.py разбирает статью-список, сопоставляет названия с QID Wikidata и оставляет только людей; результат — data/domain.csv.

	A	B	C	D	E	F	G	H
1	№	Команда	Предметная область					
2	1	Сычков, Кидысюк, Тищенко, Жильцов	pyTorch					
3	2	Кабанцов, Епишин	Античные философы					
4	3	Васильева, Карапузова, Касумова, Метлина	K-pop					
5	4	Олехова, Ищенко, Мацакова, Сушенцов	цифровые художники					
6	5	Спиридонов	100 величайших исполнителей всех времён по версии журнала Rolling Stone(сольные исполнители, не группы)					

Проверка требований

Требование	Факт	Вывод
30-60 сущностей одного основного класса (Q5)	53 из 53 - люди	выполнено
у большинства >= 5 заполненных свойств	53 из 53 (100%)	выполнено
среди них есть даты и числа	дата и число и >= 5 свойств: 41 из 53 (77%)	выполнено
хотя бы одно свойство с квалификатором времени	найдено свойств: 9	выполнено
текстовое описание по большинству сущностей	53 из 53 (100%)	выполнено

Заполненность основных свойств

Заполненность — доля сущностей домена (из 53), у которых свойство имеет хотя бы одно значение

Свойство	Название	Тип	Заполнено (из 53)	Доля
wdt:P19	место рождения	объект	53	100%
wdt:P27	гражданство	объект	53	100%
wdt:P106	род занятий	объект	53	100%
wdt:P136	жанр	объект	53	100%
wdt:P264	лейбл	объект	53	100%
wdt:P166	награда	объект	53	100%
wdt:P569	дата рождения	дата	53	100%
wdt:P2031	начало активности	дата	53	100%
wdt:P1303	инструмент	объект	51	96%
wdt:P856	официальный сайт	ссылка	49	93%
wdt:P463	член организации	объект	44	83%
wdt:P26	супруг(а)	объект	39	74%
wdt:P8687	число подписчиков	число	39	74%
wdt:P570	дата смерти	дата	34	64%
wdt:P2032	конец активности	дата	26	49%
wdt:P1971	число детей	число	15	28%
wdt:P2048	рост	число	12	23%

Свойства с квалификатором времени

Свойство	Квалификатор времени	Сущностей	Доля	Утверждений
wdt:P166 полученные награды	P585 момент времени	52	98%	352
wdt:P8687 количество подписчиков в соцсети	P585 момент времени	39	74%	246
wdt:P26 супруг(а)	P580 дата начала	36	68%	67
wdt:P26 супруг(а)	P582 дата окончания	34	64%	59
wdt:P463 участник организации или коллектива	P580 дата начала	7	13%	18
wdt:P463 участник организации или коллектива	P582 дата окончания	7	13%	18
wdt:P264 лейбл звукозаписи	P580 дата начала	4	8%	12
wdt:P264 лейбл звукозаписи	P582 дата окончания	3	6%	7
wdt:P27 гражданство	P580 дата начала	3	6%	3
wdt:P166 полученные награды	P580 дата начала	2	4%	2
wdt:P856 официальный сайт	P813 дата проверки	1	2%	1
wdt:P856 официальный сайт	P2960 дата архивирования	1	2%	1
wdt:P856 официальный сайт	P580 дата начала	1	2%	2
wdt:P856 официальный сайт	P582 дата окончания	1	2%	2
wdt:P136 жанр	P580 дата начала	1	2%	1
wdt:P136 жанр	P582 дата окончания	1	2%	1
wdt:P2031 начало периода активности	P1326 не позднее	1	2%	1
wdt:P27 гражданство	P582 дата окончания	1	2%	1

В онтологии и графе смоделированы три наиболее массовых случая: награды с моментом времени (P166 + P585, 52 сущности, 352 утверждения), число подписчиков на дату (P8687 + P585, 39 сущностей, 246 утверждений) и браки с датами начала и конца (P26 + P580/P582, 36 и 34 сущности). Они вынесены в отдельные узлы-факты (AwardReceipt, FollowersSnapshot, Marriage, разделы 3–4). Квалификаторы у P463, P264, P27, P856, P136, P2031 встречаются у единиц сущностей и в граф не переносились.

Источники текстовой информации

Для каждой из 53 сущностей есть две статьи Википедии — русская и английская (всего 106 документов, лицензия CC BY-SA 4.0; требование «по большинству сущностей есть текст» выполнено для 100%).

Вывод

Домен «исполнители Rolling Stone 100» удовлетворяет всем четырём требованиям: 53 сущности одного класса Q5, у всех ≥ 5 свойств (в том числе даты и числа — у 77%), найдено 9 свойств с квалификатором времени, тексты есть у 100% сущностей.

2. Вопросы к базе знаний

Банк вопросов, эталоны и проверочные запросы хранятся в scripts/task2_questions.py. При запуске скрипт загружает граф и онтологию (8 062 тройки), выполняет SPARQL-запросы для вопросов 1–6 и сверяет результат с эталоном; для вопросов 7–12 проверяет, что каждая цитата дословно встречается в тексте соответствующей статьи корпуса; для комбинированных вопросов (11, 12) дополнительно проверяет, что граф находит ожидаемую сущность. Запуск 2026-11-10 13:51:51–13:51:53, код возврата 0, расхождений нет — все 12 эталонов помечены «совпало» (questions_results.json).

Вопросы, на которые отвечает граф (1–6)

№	Тип	Вопрос	Эталонный ответ	Запуск
1	фильтр по дате	Кто из музыкантов родился 1 января 1960 года или позже?	Доктор Дре, JAŸ-Z, Тупак Шакур, Эминем	совпало
2	агрегация	Сколько музыкантов в базе всего и сколько из них умерли?	Всего 53, умерли 34	совпало
3	сортировка + агрегация	У каких трёх музыкантов больше всего полученных наград?	Арета Франклин (44), Элтон Джон (27), Боб Дилан (25)	совпало
4	многошаговый (2 ребра)	Кто из музыкантов списка состоял в той же группе, что и Рой Орбисон?	Том Петти, Боб Дилан	совпало
5	квалификатор времени	Кто был супругом Джона Леннона в 1970 году?	Йоко Оно	совпало
6	фильтр по числу + сортировка	Какие музыканты выше 180 см? Перечислить по убыванию роста.	Джонни Кэш (188), Карл Перкинс (185), Фрэнк Заппа (183)	совпало

Эталонные ответы и результаты запуска (questions_results.json) совпадают; Q3 и Q6 — с числовыми значениями (награды: 44, 27, 25; рост: 188, 185, 183 см).

Вопросы, ответ на которые есть только в тексте (7–10)

Вопрос 7

Вопрос	Почему публика освистала Боба Дилана на фолк-фестивале в Ньюпорте в 1965 году?
Эталонный ответ	Дилан вышел на сцену с электрогитарой, чего фолк-публика не ждала; освистывали фолк-поклонники, которых он этим отдалил. Он сыграл три песни и ушёл со сцены.
Цитата из текста	«he was met with cheering and booing and left the stage after three songs» «the boos were from folk fans whom Dylan had alienated by appearing, unexpectedly, with an electric guitar»
Источник	https://en.wikipedia.org/wiki/Bob_Dylan
Почему ответа нет в графе	В графе нет событий, выступлений и реакции публики: только даты, места, награды, браки; причины и мотивы — это повествование, которого нет в Wikidata-свойствах онтологии.
Проверка запуском	совпало (цитаты найдены в статье корпуса дословно)

Вопрос 8

Вопрос	Что считается причиной нападения на Боба Марли в 1976 году?
Эталонный ответ	Нападение произошло за два дня до концерта «Smile Jamaica»; считается, что оно имело политические мотивы, так как многие воспринимали концерт как митинг в поддержку Майкла Мэнли.
Цитата из текста	«two days before "Smile Jamaica"» «believed to have been politically motivated, as many felt that Smile Jamaica was actually a support rally for Manley»
Источник	https://en.wikipedia.org/wiki/Bob_Marley
Почему ответа нет в графе	Мотивы и политический контекст происшествия не представлены в графе: нет класса «событие» и связи музыканта с такими событиями; ответ — интерпретация в тексте статьи.
Проверка запуском	совпало (цитаты найдены в статье корпуса дословно)

Вопрос 9

Вопрос	От чего умер Джими Хендрикс?
Эталонный ответ	Он задохнулся (асфиксия) от аспирации собственной рвоты, будучи в состоянии интоксикации барбитуратами (доза превышала рекомендованную в 18 раз).
Цитата из текста	«aspirated his own vomit and died of asphyxia while intoxicated with barbiturates» «18 times the recommended dosage»
Источник	https://en.wikipedia.org/wiki/Jimi_Hendrix

Почему ответа нет в графе	В графе есть только дата смерти (deathDate); у онтологии нет свойства «причина смерти», а обстоятельства смерти описаны только в тексте.
Проверка запуском	совпало (цитаты найдены в статье корпуса дословно)

Вопрос 10

Вопрос	Откуда у Мадди Уотерса прозвище «Muddy»?
Эталонный ответ	Прозвище «Muddy» он получил ещё в детстве, потому что любил играть в грязной воде ручья Дир-Крик.
Цитата из текста	«gave him the nickname "Muddy" at an early age because he loved to play in the muddy water of nearby Deer Creek»
Источник	https://en.wikipedia.org/wiki/Muddy_Waters
Почему ответа нет в графе	Прозвища и их происхождение не моделируются в онтологии (есть только метки rdfs:label); история прозвища есть только в тексте.
Проверка запуском	совпало (цитаты найдены в статье корпуса дословно)

Комбинированные вопросы (11–12)

Вопрос 11

Вопрос	Что известно об обстоятельствах гибели самого молодого из умерших музыкантов списка?
Что берём из графа	Среди музыкантов с birthDate и deathDate вычислить возраст на момент смерти и выбрать минимальный → Бадди Холли (Q5977), 22 года; берётся ссылка wikipediaEn на его статью.
Что берём из текста	В разделе «Death» статьи: самолёт разбился вскоре после взлёта, погибли Холли, Ричи Валенс, Биг Боппер и пилот Роджер Питерсон; вылет в плохую погоду, пилот не имел права летать только по приборам.
Эталонный ответ	Самый молодой из умерших — Бадди Холли (22 года). Он погиб при крушении самолёта вскоре после взлёта вместе с Ричи Валенсом, Биг Боппером и пилотом Роджером Питерсоном; самолёт вылетел в плохую погоду, а пилот не был сертифицирован для полётов только по приборам.
Источник текста	https://en.wikipedia.org/wiki/Buddy_Holly
Проверка запуском	совпало (граф находит ожидаемую сущность: Бадди Холли, возраст 22)

Вопрос 12

Вопрос	Как началась музыкальная карьера музыканта с наибольшим числом наград?
Что берём из графа	Агрегация: по числу hasAwardReceipt выбрать музыканта-лидера → Арета Франклин (Q125121), 44 награды; берётся ссылка wikipediaEn.

Что берём из текста	Из статьи: её заметили благодаря исполнению госпела в баптистской церкви New Bethel в Детройте.
Эталонный ответ	Больше всего наград у Ареты Франклин (44). Её заметили как певицу госпела в баптистской церкви New Bethel в Детройте.
Источник текста	https://en.wikipedia.org/wiki/Aretha_Franklin
Проверка запуском	совпало (граф находит ожидаемую сущность: Арета Франклин, 44 награды)

Вывод

Банк из 12 вопросов соответствует условию (6 + 4 + 2); для вопросов по графу выполнены все обязательные виды; все эталоны воспроизводятся запуском task2_questions.py.

3. Онтология домена

Стартовая онтология создана скриптом task3_build_ontology.py, затем доработана (owl:disjointWith, функциональные свойства, метаданные) и сохранена в Turtle — data/ontology.ttl (324 тройки). Пространство имён: http://example.org/rs100/onto# (префикс :); данные графа — в http://example.org/rs100/res/ (префикс res:); сама онтология объявлена как http://example.org/rs100/onto (owl:Ontology, версия 1.0, подписи на ru и en).

Три показателя в Wikidata сопровождаются квалификаторами времени (награда с годом, число подписчиков на дату, брак с датами). Чтобы сохранить эти данные в графе, они смоделированы отдельными узлами-фактами: AwardReceipt (свойства award, awardYear), FollowersSnapshot (followersCount, followersDate), Marriage (spouse, marriageStart, marriageEnd); музыкант связывается с ними свойствами hasAwardReceipt, hasFollowers, hasMarriage. Это позволяет отвечать на вопросы с квалификатором времени (Q5) и фильтровать награды по годам.

Классы и иерархия

Классы онтологии

Класс	Label (en / ru)	Надкласс	≡ Wikidata	disjointWith
:Agent	Agent / Агент	—	—	:Place
:Award	Award / Награда	—	wd:Q618779	:AwardReceipt
:AwardReceipt	Award receipt / Получение награды	—	—	:FollowersSnapshot
:Country	Country / Страна	:Place	wd:Q6256	—
:FollowersSnapshot	Followers snapshot / Число подписчиков на дату	—	—	—
:Genre	Music genre / Музыкальный жанр	—	wd:Q188451	:Instrument, :Occupation

:Instrument	Musical instrument / Музыкальный инструмент	—	wd:Q34379	—
:Marriage	Marriage / Брак	—	—	:AwardReceipt, :FollowersSnapshot
:MusicalGroup	Musical group / Музыкальная группа	:Organization	wd:Q215380	—
:Musician	Musician / Музыкант	:Person	—	—
:Occupation	Occupation / Род занятий	—	wd:Q12737077	:Instrument
:Organization	Organization / Организация	:Agent	—	—
:Person	Person / Человек	:Agent	wd:Q5	:Organization
:Place	Place / Место	—	wd:Q17334923	—
:RecordLabel	Record label / Звукозаписывающий лейбл	:Organization	wd:Q18127	—

У всех 15 классов есть rdfs:label на русском и английском и rdfs:comment на обоих языках. Эквивалентности к Wikidata заданы для 9 классов; для Musician, Organization, Agent и служебных классов (AwardReceipt, FollowersSnapshot, Marriage) аналогов в Wikidata нет или они слишком общие, поэтому связь не задавалась.

Свойства

Объектные свойства (owl:ObjectProperty) — 12

Свойство	Функц.	Domain	Range	≡ Wikidata
award	да	AwardReceipt	Award	—
birthPlace	да	Musician	Place	wdt:P19
citizenship	—	Person	Country	wdt:P27
genre	—	Musician	Genre	wdt:P136
hasAwardReceipt	—	Musician	AwardReceipt	—
hasFollowers	—	Musician	FollowersSnapshot	—
hasMarriage	—	Person	Marriage	—
memberOf	—	Musician	Organization	wdt:P463
occupation	—	Person	Occupation	wdt:P106
playsInstrument	—	Musician	Instrument	wdt:P1303
recordLabel	—	Musician	RecordLabel	wdt:P264
spouse	да	Marriage	Person	—

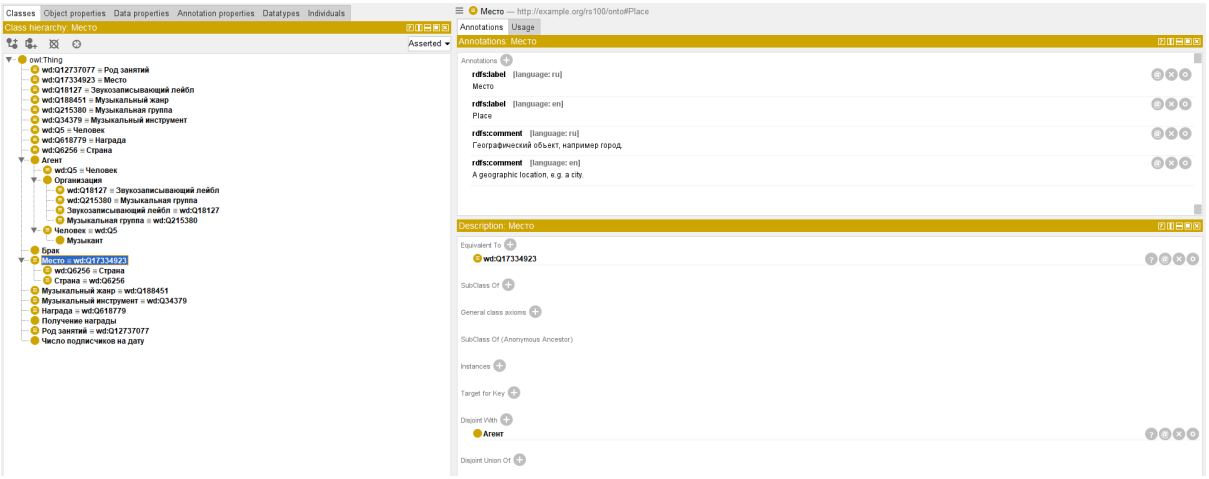
Свойства-данные (owl:DatatypeProperty) — 15

Свойство	Функц.	Domain	Range	≡ Wikidata
activeFromYear	—	Musician	xsd:gYear	wdt:P2031
activeUntilYear	—	Musician	xsd:gYear	wdt:P2032
awardYear	да	AwardReceipt	xsd:gYear	—
birthDate	да	Person	xsd:date	wdt:P569
childrenCount	да	Person	xsd:integer	wdt:P1971
deathDate	да	Person	xsd:date	wdt:P570
followersCount	да	FollowersSnapshot	xsd:integer	wdt:P8687
followersDate	да	FollowersSnapshot	xsd:date	—
heightCm	да	Person	xsd:decimal	wdt:P2048
marriageEnd	да	Marriage	xsd:date	—
marriageStart	да	Marriage	xsd:date	—
officialWebsite	—	Agent	xsd:anyURI	wdt:P856
rsRank	да	Musician	xsd:integer	—
wikipediaEn	да	Agent	xsd:anyURI	—
wikipediaRu	да	Agent	xsd:anyURI	—

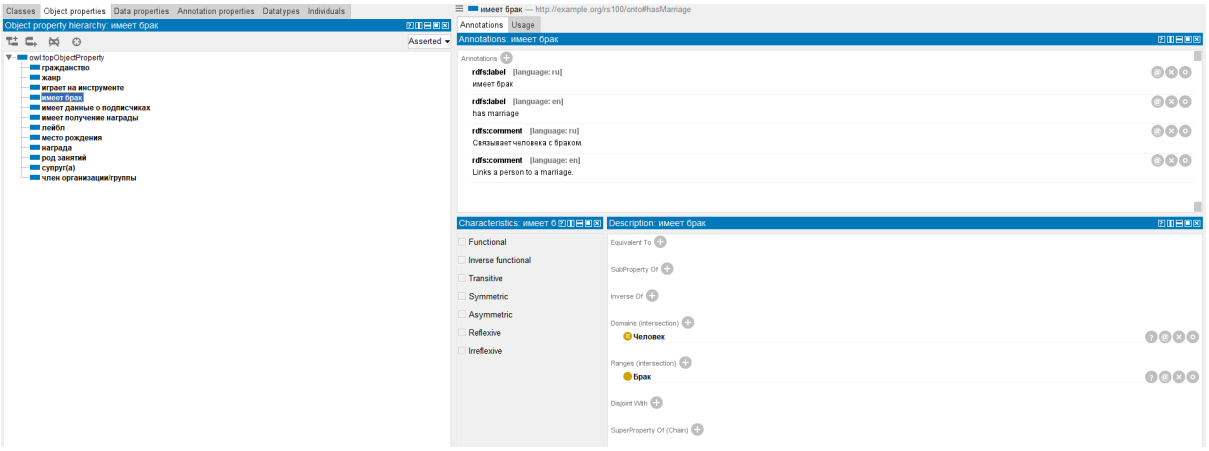
Функциональные свойства (15): award, awardYear, birthDate, birthPlace, childrenCount, deathDate, followersCount, followersDate, heightCm, marriageEnd, marriageStart, rsRank, spouse, wikipediaEn, wikipediaRu.

Скриншоты Protégé

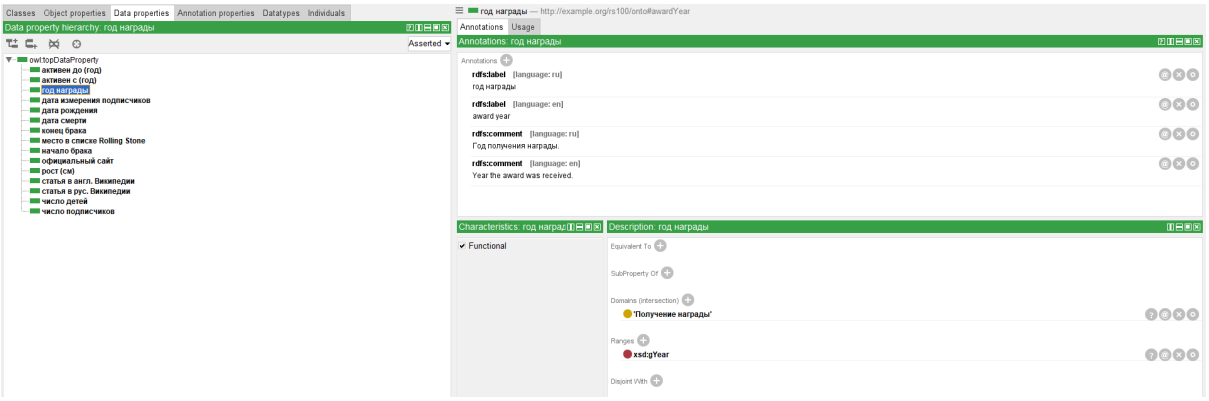
Дерево классов онтологии в Protégé



Объектные свойства с domain и range



Свойства-данные с domain и range



Свойства аннотации

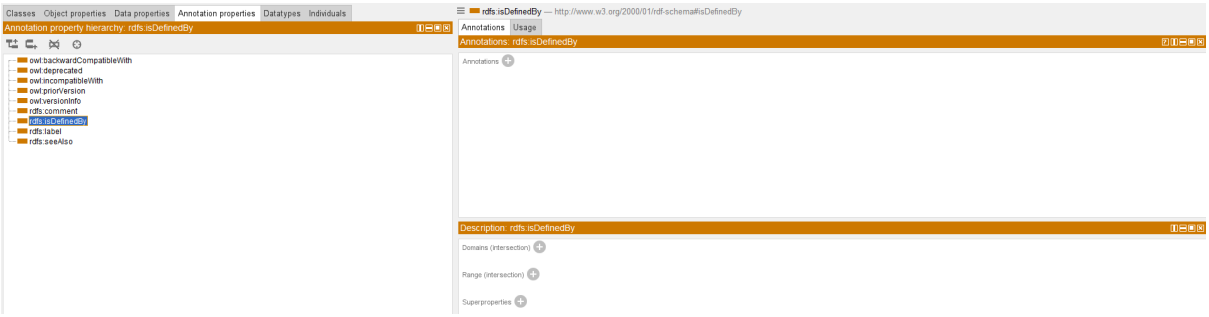


Таблица «вопрос → классы и свойства»

Вопрос	Классы	Свойства
Q1	Musician	birthDate
Q2	Musician	deathDate
Q3	Musician, AwardReceipt	hasAwardReceipt
Q4	Musician, Organization	memberOf
Q5	Person, Marriage	hasMarriage, spouse, marriageStart, marriageEnd

Q6	Musician	heightCm
Q7	Musician	wikipediaEn
Q8	Musician	wikipediaEn
Q9	Musician	wikipediaEn
Q10	Musician	wikipediaEn
Q11	Musician	birthDate, deathDate, wikipediaEn
Q12	Musician, AwardReceipt	hasAwardReceipt, wikipediaEn

В вопросах задействовано 10 из 27 свойств (birthDate, deathDate, hasAwardReceipt, memberOf, hasMarriage, spouse, marriageStart, marriageEnd, heightCm, wikipediaEn) и 5 из 15 классов (Musician, Person, AwardReceipt, Organization, Marriage).

Свойства, не использованные в вопросах, и пояснение, зачем они нужны

Свойство	Зачем нужно
activeFromYear	дата начала карьеры - временное свойство основного класса (требование: даты)
activeUntilYear	дата окончания карьеры - временное свойство основного класса (требование: даты)
award	связывает факт получения награды (AwardReceipt) с самой наградой; без него hasAwardReceipt (Q3, Q12) не описывает, какая награда получена
awardYear	квалификатор времени награды (требование домена: свойство с временным квалификатором); основа для вопросов вида «награды за 1990-е»
birthPlace	функциональное объектное свойство основного класса (место рождения, класс Place); нужно для условия «>=5 свойств» и для расширений («кто родился в городе N»)
childrenCount	числовое свойство основного класса (требование: числа)
citizenship	описание основного класса (объектное свойство к Country); нужно для условия домена «>=5 свойств» и для расширений (фильтр по стране)
followersCount	числовой показатель с датой измерения (требование домена: числа и квалификатор времени)
followersDate	квалификатор времени для followersCount
genre	описание основного класса (объектное свойство к Genre); нужно для условия «>=5 свойств»
hasFollowers	связывает музыканта с замером числа подписчиков (числовой показатель с датой, требование домена)
occupation	описание основного класса (объектное свойство к Occupation); нужно для условия «>=5 свойств»
officialWebsite	ссылка на внешний источник сведений о сущности (не вопрос, а provenance)

playsInstrument	описание основного класса (объектное свойство к Instrument); нужно для условия «>=5 свойств»
recordLabel	описание основного класса (объектное свойство к RecordLabel); нужно для условия «>=5 свойств»
rsRank	место в списке Rolling Stone - основание принадлежности сущности к домену
wikipediaRu	ссылка на русскую статью - источник текста для корпуса (task5); параллель к wikipediaEn

Классы, не использованные в вопросах

Класс	Зачем нужен
Agent	надкласс иерархии (Person, Organization); нужен для domain у wikipediaEn/wikipediaRu/officialWebsite
Award	тип значений award
Country	тип значений citizenship
FollowersSnapshot	тип узла-замера подписчиков (hasFollowers)
Genre	тип значений genre
Instrument	тип значений playsInstrument
MusicalGroup	подкласс Organization для групп; значения memberOf (Q4) - группы, класс уточняет их тип
Occupation	тип значений occupation
Place	тип значений birthPlace
RecordLabel	тип значений recordLabel

Проверка требований

Требование	Результат	Детали
не меньше 5 классов	выполнено	классов: 15
есть иерархия классов	выполнено	отношений subClassOf: 6
есть object- и datatype-свойства	выполнено	object: 12, datatype: 15
у всех свойств указан domain	выполнено	—
у всех свойств указан range	выполнено	—
есть функциональное свойство	выполнено	функциональных: 15
у всех классов и свойств есть label (ru, en) и comment	выполнено	—
все классы и свойства в собственном пространстве имён	выполнено	—

domain/range объектных свойств - классы онтологии	выполнено	—
указаны owl:equivalentClass / owl:equivalentProperty к Wikidata	выполнено	классов: 9, свойств: 15
всё упомянутое в таблице вопросов есть в онтологии	выполнено	—

Вывод

Онтология содержит 15 классов с иерархией, 12 объектных и 15 datatype-свойств с domain и range, 15 функциональных свойств, двуязычные подписи и комментарии для всех сущностей онтологии, связи с Wikidata для 9 классов и 15 свойств; всё находится в собственном пространстве имён и сохранено в Turtle.

4. Граф знаний

Скрипт task4_build_graph.py по списку QID из domain.csv запрашивает у Wikidata значения свойств, преобразует их в термины онтологии (:Musician, :birthDate, :hasAwardReceipt и т. д.) и записывает data/graph.ttl (Turtle, 262 989 байт). Сущности справочников (места, жанры, награды, лейблы, организации и т. п.) получают URI res:Q…, тип из онтологии, rdfs:label (ru/en) и owl:sameAs wd:Q…. Квалифицированные факты (награды, браки, подписчики) записываются узлами res:Q…_award_N, res:Q…_marriage_N, res:Q…_followers_N. Классы Wikidata в rdf:type не используются.

Общая статистика

Показатель	Значение
Троек в графе данных	7 738 (онтология отдельно — 324; вместе — 8 062)
Узлов с типом (сущностей всего)	1 538
— сущностей Wikidata (имеют owl:sameAs)	798, из них основной класс Musician — 53
— служебных узлов-фактов (AwardReceipt, Marriage, FollowersSnapshot)	740 (424 + 70 + 246)
Различных классов (в rdf:type графа)	13
Различных предикатов	30
Троек с объектными свойствами	2 645
Троек с datatype-свойствами	1 296

Баланс: 1539 (rdf:type) + 1460 (rdfs:label) + 798 (owl:sameAs) + 2645 (объектные) + 1296 (datatype) = 7738. Служебные узлы-факты не соответствуют отдельным сущностям Wikidata и собственного QID не имеют, поэтому owl:sameAs у них не задаётся; каждый однозначно привязан к музыканту через hasAwardReceipt, hasMarriage или hasFollowers. Для всех 798 сущностей Wikidata owl:sameAs присутствует и ведёт на wd: с тем же QID.

Проверки качества графа

Проверка	Результат
у каждой сущности Wikidata есть owl:sameAs	выполнено
sameAs ведёт на wd:<тот же QID>	выполнено
все классы графа определены в онтологии	выполнено
все свойства графа определены в онтологии (или owl/rdf/rdfs)	выполнено
в графе нет классов Wikidata в rdf:type	выполнено

Разбивка по классам

«Прямые» экземпляры — по rdf:type в графе; «с подклассами» — с учётом иерархии онтологии (Musician считается также Person и Agent). Класс Agent в графе напрямую не используется, поэтому в rdf:type встречается 13 различных классов, а в таблице строк 14.

Класс	Прямых экземпляров	С учётом подклассов
:AwardReceipt	424	424
:Agent	0	338
:FollowersSnapshot	246	246
:Organization	85	216
:Award	177	177
:RecordLabel	131	131
:Person	69	122
:Genre	91	91
:Occupation	85	85
:Marriage	70	70
:Place	60	66
:Musician	53	53
:Instrument	41	41
:Country	7	7

Разбивка по свойствам

«Музыкантов с ним» — число музыкантов, у которых есть хотя бы одно значение; доля — от 53 музыкантов. Нулевые значения у award, awardYear, followersCount, followersDate, spouse, marriageStart, marriageEnd ожидаемы: эти свойства стоят у узлов-фактов, а не у музыкантов.

Свойство	Вид	Троек	Субъектов	Музыкантов с ним	Доля
rdf:type	rdf:type	1539	1538	53	100%

rdfs:label	owl/rdfs	1460	794	53	100%
owl:sameAs	owl/rdfs	798	798	53	100%
:occupation	object	498	53	53	100%
:award	object	424	424	0	0%
:hasAwardReceipt	object	424	53	53	100%
:awardYear	datatype	345	345	0	0%
:genre	object	280	53	53	100%
:recordLabel	object	246	53	53	100%
:followersCount	datatype	246	246	0	0%
:followersDate	datatype	246	246	0	0%
:hasFollowers	object	246	39	39	74%
:playsInstrument	object	182	51	51	96%
:memberOf	object	92	44	44	83%
:spouse	object	70	70	0	0%
:hasMarriage	object	70	39	39	74%
:citizenship	object	60	53	53	100%
:rsRank	datatype	53	53	53	100%
:birthPlace	object	53	53	53	100%
:wikipediaRu	datatype	53	53	53	100%
:wikipediaEn	datatype	53	53	53	100%
:birthDate	datatype	53	53	53	100%
:activeFromYear	datatype	52	52	52	98%
:officialWebsite	datatype	49	49	49	92%
:deathDate	datatype	34	34	34	64%
:marriageStart	datatype	33	33	0	0%
:activeUntilYear	datatype	26	26	26	49%
:marriageEnd	datatype	26	26	0	0%
:childrenCount	datatype	15	15	15	28%
:heightCm	datatype	12	12	12	23%

Соответствие заполненности Wikidata и графа

Доли заполненности свойств у музыкантов в графе совпадают с долями из задания 1 (рождение, смерть, жанр, лейбл, инструмент, организация, сайт, подписчики, число детей, рост).

Вывод

Граф содержит 7 738 троек и 1 538 узлов, описан только терминами собственной онтологии (13 классов, 30 предикатов); все 798 сущностей Wikidata связаны owl:sameAs; граф сохранён в data/graph.ttl (Turtle).

Корпус текстов

Скрипт task5_build_corpus.py для каждого из 53 QID получает через API Википедии тексты русской и английской статей (plain text без разметки) и записывает их в data/corpus.jsonl (одна статья — одна строка, 5 544 606 байт). Проверку выполняет task5_check_corpus.py (запуск 13:51:45, код возврата 0).

Структура записи корпуса

Поле	Содержимое
id	<QID>:<язык>wiki, уникальный идентификатор документа
qid	идентификатор сущности в Wikidata (связь с owl:sameAs в графе)
entity	название сущности (метка ru, иначе en)
source, lang	источник (wikipedia) и язык статьи (ru/en)
title, url	заголовок статьи и ссылка на неё
license	лицензия источника (CC BY-SA 4.0)
n_chars	число символов в text
text	полный текст статьи без разметки (plain text через API Википедии)

Статистика корпуса

Показатель	Значение
Документов	106 (все с текстом ≥ 500 символов)
Сущностей в домене / с текстом / с ru и en	53 / 53 / 53
По языкам	en — 53, ru — 53
По источникам	wikipedia — 106
Объём	4 363 148 символов
Размер документа (символов)	min 2 326; медиана 33 784; max 137 826
Лицензия	CC BY-SA 4.0
Суммарно по сущности	от 17 590 (Эл Грин) до 217 522 (Боб Дилан) символов (ru + en)

Проверки корпуса

Проверка	Результат
все строки — корректный JSON с обязательными полями, n_chars совпадает с длиной	выполнено
id документов уникальны	выполнено

у каждой сущности домена есть хотя бы один источник с текстом (≥500 символов)	выполнено
в корпусе нет сущностей вне домена	выполнено

Источники по сущностям

Для каждой сущности источник текста — статья русской и английской Википедии; ссылки по каждой сущности приведены в приложении В (файл corpus_entities.csv, совпадает с text_sources.csv по составу ссылок).

Вывод
Корпус покрывает 100% сущностей домена (53 из 53) двумя независимыми источниками каждую, структура записей позволяет связать текст с графом через qid и owl:sameAs.

6. Проверка данных и логический вывод

Ограничения SHACL

Ограничения записаны в shapes/task6_shapes.ttl (148 троек) и заданы формами для четырёх классов: Musician, AwardReceipt, Marriage, FollowersSnapshot. Проверено шесть видов ограничений (больше требуемых трёх):

Вид ограничения	Компонент SHACL	Примеры в формах
Кардинальность	sh:minCount, sh:maxCount	rsRank и birthDate: ровно одно значение; birthPlace, deathDate, heightCm: не более одного; AwardReceipt: ровно одна award и один awardYear; Marriage: ровно один spouse
Тип данных	sh:datatype	birthDate, deathDate, marriageStart/End — xsd:date; rsRank, followersCount, childrenCount — xsd:integer; heightCm — xsd:decimal; activeFromYear, awardYear — xsd:gYear; сайты и ссылки — xsd:anyURI
Класс значения	sh:class	birthPlace → Place; citizenship → Country; occupation → Occupation; genre → Genre; recordLabel → RecordLabel; memberOf → Organization; playsInstrument → Instrument; award → Award; spouse → Person
Диапазон	sh:minInclusive, sh:maxInclusive	rsRank 1–100; birthDate 1850-01-01…2010-12-31; deathDate ≤ 2026-12-31; heightCm 120–250; childrenCount 0–30; followersCount ≥ 0
Шаблон	sh:pattern	officialWebsite — ^https?://; wikipediaEn — ^https://en\.wikipedia\.org/wiki/; wikipediaRu — аналогично для ru; awardYear — ^(19|20)[0-9]{2}$

Порядок значений	sh:lessThan	birthDate < deathDate; marriageStart < marriageEnd

Ограничения awardYear (AwardReceipt) и followersDate (FollowersSnapshot) заданы с уровнем sh:Warning: в Wikidata квалификатор времени указан не всегда, и пропуск — свойство источника данных, а не ошибка преобразования.

Результат pyshacl

Запуск task6_validate_and_infer.py (2026-11-10 13:52:03–13:52:43, код возврата 0). Проверялся граф data/graph.ttl (7 738 троек) по формам task6_shapes.ttl, онтология подключена как ont_graph (324 тройки). Время работы pyshacl — 0,3 с.

Нарушений уровня sh:Violation нет: ограничения на тип данных, класс значения, диапазон, шаблон и порядок значений выполнены для всех данных. Все 79 результатов — предупреждения одного вида (кардинальность awardYear). Полный отчёт: shacl_report.txt и shacl_report.ttl.

Нарушения по видам и решения

Вид нарушения	Узлов	Что сделано и почему
Кардинальность (min) — MinCountConstraintComponent, путь :awardYear; уровень Warning	79 (40 музыкантов; больше всего — у Элтона Джона, 6)	Ограничение ослаблено до sh:Warning, данные не изменялись — нарушение оставлено. У 79 из 424 фактов получения награды в Wikidata нет квалификатора «момент времени» (P585): 424 − 345 (с годом) = 79. Год награды нельзя выдумывать или подставлять по догадке, поэтому данные не правились; требовать год как жёсткое ограничение означало бы объявлять недостатком графа неполноту источника, поэтому форма оставлена с уровнем Warning, а пропуски зафиксированы в отчёте.

Других типов нарушений нет, поэтому решений «данные исправлены» и «ограничение ослаблено по другим свойствам» в этой работе не потребовалось; followersDate (Warning) нарушений не дал: все 246 замеров подписчиков имеют дату.

Логический вывод (owlrl)

Использована семантика OWL 2 RL (owlrl). Вход — граф вместе с онтологией (8 062 тройки). Выведено 26 518 новых троек; после отбрасывания тривиальных (rdfs:Resource, owl:Thing, рефлексивные) осталось 18 164; они сохранены в inferred_triples.ttl. Время работы owlrl — 36,6 с.

Категория	Троек	Пример добавленной тройки

свойства, скопированные на wd:Q… через owl:sameAs	10 566	wd:Q100 rdf:type :Place
эквивалентные свойства Wikidata (wdt:P…) через owl:equivalentProperty	3 309	res:Q1203 wdt:P106 res:Q10774753
прочее	1 976	res:Q1203 :birthPlace wd:Q24826
owl:sameAs: симметрия и транзитивность (wd:Q… sameAs res:Q…)	798	wd:Q100 owl:sameAs res:Q100
эквивалентные классы Wikidata через owl:equivalentClass	720	res:Q100 rdf:type wd:Q17334923
rdf:type по иерархии классов (Musician → Person → Agent и т. д.)	528	res:Q10303978 rdf:type :Agent
выводы над онтологией (подклассы, подсвойства, домены)	267	:Agent rdfs:subClassOf owl:Thing

Итого по категориям: 10 566 + 3 309 + 1 976 + 798 + 720 + 528 + 267 = 18 164.

Эффект вывода на число экземпляров классов

Класс	В исходном графе	После вывода	С подклассами в исходном графе (п. 4.4)
:Musician	53	106	53
:Person	69	244	122
:Agent	0	676	338
:Organization	85	432	216
:RecordLabel	131	262	131
:Place	60	132	66
:Country	7	14	7

Наблюдение: число экземпляров после вывода равно ровно удвоенному числу экземпляров «с подклассами» (Agent: 338 → 676; Organization: 216 → 432; Person: 122 → 244; Musician: 53 → 106 и т. д.). Это следствие owl:sameAs: каждый узел res:Q… получает «двойника» wd:Q… с тем же набором типов и свойств. Новая информация по существу — это (1) иерархические типы (Agent, Person, Organization для узлов, которые в графе были типизированы только подклассом), (2) термины Wikidata (wd:Q5, wdt:P…) и (3) зеркалирование описаний на wd-узлы.

Вывод

Граф удовлетворяет всем ограничениям SHACL уровня Violation (Conforms = True); 79 предупреждений о незаполненном годе награды объясняются неполнотой Wikidata и

оставлены. Вывод OWL RL добавил 18 164 значимых тройки, показав иерархические типы, соответствия Wikidata и зеркалирование через owl:sameAs.